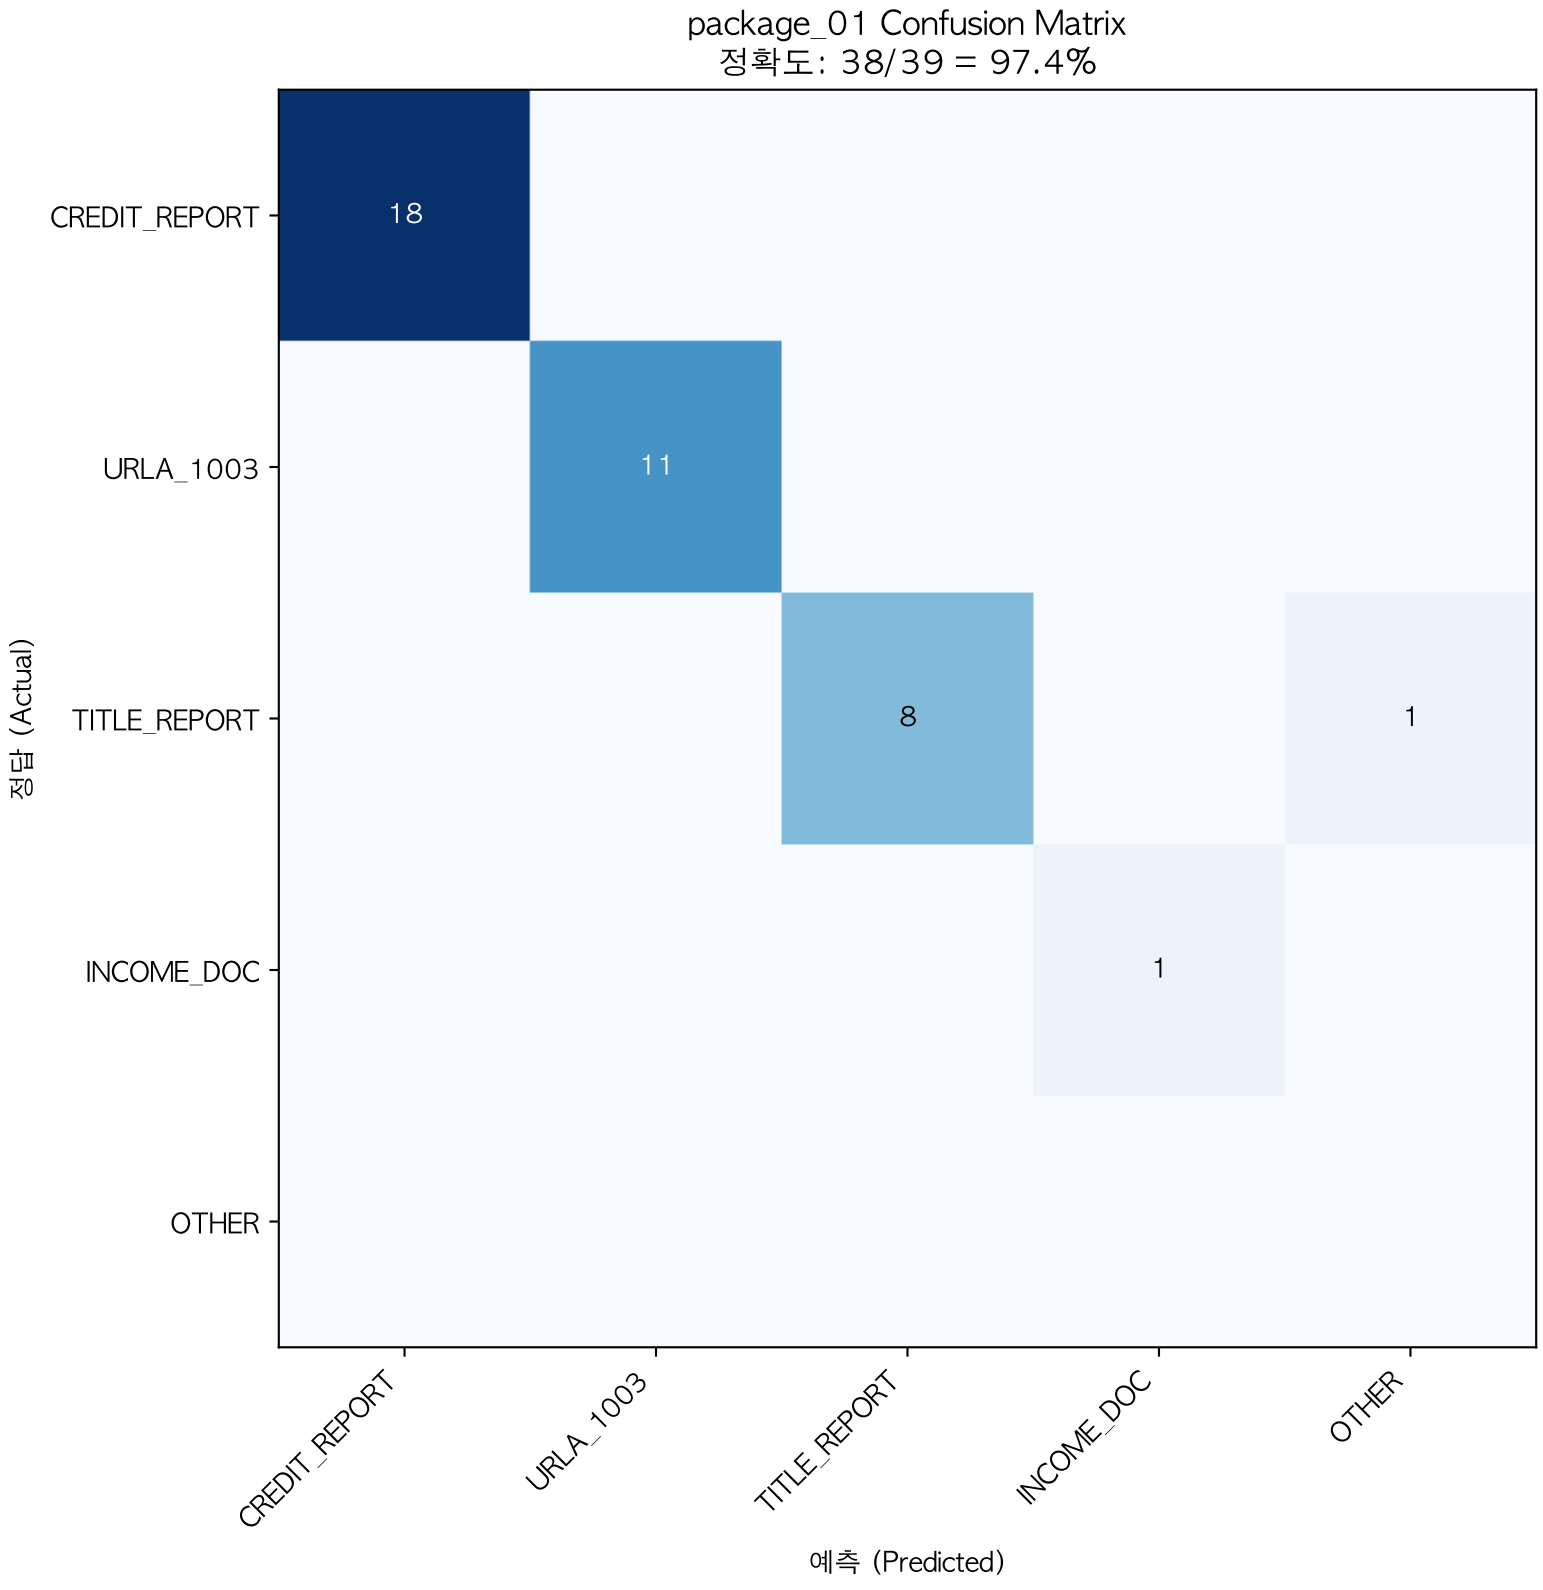
MK Lending 대출서류 분류 프로젝트

파이프라인 구조
1. extract.py PDF 페이지별 텍스트 추출 + 반전 아티팩트 복원
2. rule_classifier 정규식 키워드 기반 1차 분류
3. llm_classifier 정규식이 아무 것도 못 찾은 페이지만
Groq -〉 Cerebras 폴백으로 재분류
4. grouping.py 연속된 동일 카테고리 페이지를 문서 단위로 그룹핑
5. evaluate.py 정답(GT) 대비 정확도 / confusion matrix 산출

핵심 결과 (package_01, 정답 있음)
- 정확도: 38/39 = 97.4%
- 규칙 기반으로 38페이지, LLM 폴백은 정확히 1페이지(page 8)만 호출됨

package_02 (44페이지, 정답 없음) 분류 결과도 본 리포트에 포함

주요 발견 및 한계
- 일부 페이지가 PDF /Rotate 메타데이터(90/180/270도)로 인해
텍스트가 반전/뒤섞여 추출됨 (원본 개별 문서엔 없던 현상,
병합 과정에서 생긴 것으로 추정) -〉 흔한 영어 단어 매칭
개수 비교 휴리스틱으로 감지/복원, 산출물 PDF는 회전
정규화(split_by_category.py)로 시각적으로도 복원
- 두 shuffled 파일 모두 페이지 단위로 완전히 랜덤 셔플되어 있어
인접 페이지가 같은 카테고리인 경우가 전무함
-〉 그룹핑 결과가 항상 1페이지짜리 그룹으로 나옴
(그룹핑 로직 자체는 합성 데이터로 다중 페이지 그룹 정상 동작 검증됨)
- INCOME_DOC 카테고리는 학습/검증 가능한 예시가 1페이지뿐이라
패턴 일반화에 근본적 한계 있음


package_01 Confusion Matrix
정확도: 38/39 = 97.4%
CREDIT_REPORT
URLA_1003
TITLE_REPORT
INCOME_DOC
OTHER
18
11
8
1
1
정답 (Actual)
예측 (Predicted)

package_01 페이지별 분류 결과 (정답 대비)

Page	Category	Source	GT	결과
1	CREDIT_REPORT	rule	CREDIT_REPORT	OK
2	URLA_1003	rule	URLA_1003	OK
3	CREDIT_REPORT	rule	CREDIT_REPORT	OK
4	URLA_1003	rule	URLA_1003	OK
5	CREDIT_REPORT	rule	CREDIT_REPORT	OK
6	URLA_1003	rule	URLA_1003	OK
7	CREDIT_REPORT	rule	CREDIT_REPORT	OK
8	OTHER	llm:groq	TITLE_REPORT	X
9	CREDIT_REPORT	rule	CREDIT_REPORT	OK
10	URLA_1003	rule	URLA_1003	OK
11	CREDIT_REPORT	rule	CREDIT_REPORT	OK
12	TITLE_REPORT	rule	TITLE_REPORT	OK
13	CREDIT_REPORT	rule	CREDIT_REPORT	OK
14	URLA_1003	rule	URLA_1003	OK
15	CREDIT_REPORT	rule	CREDIT_REPORT	OK
16	TITLE_REPORT	rule	TITLE_REPORT	OK
17	CREDIT_REPORT	rule	CREDIT_REPORT	OK
18	TITLE_REPORT	rule	TITLE_REPORT	OK
19	CREDIT_REPORT	rule	CREDIT_REPORT	OK
20	URLA_1003	rule	URLA_1003	OK
21	CREDIT_REPORT	rule	CREDIT_REPORT	OK
22	TITLE_REPORT	rule	TITLE_REPORT	OK
23	CREDIT_REPORT	rule	CREDIT_REPORT	OK
24	URLA_1003	rule	URLA_1003	OK
25	CREDIT_REPORT	rule	CREDIT_REPORT	OK
26	URLA_1003	rule	URLA_1003	OK
27	CREDIT_REPORT	rule	CREDIT_REPORT	OK
28	TITLE_REPORT	rule	TITLE_REPORT	OK
29	CREDIT_REPORT	rule	CREDIT_REPORT	OK
30	URLA_1003	rule	URLA_1003	OK
31	CREDIT_REPORT	rule	CREDIT_REPORT	OK
32	TITLE_REPORT	rule	TITLE_REPORT	OK
33	CREDIT_REPORT	rule	CREDIT_REPORT	OK
34	TITLE_REPORT	rule	TITLE_REPORT	OK
35	URLA_1003	rule	URLA_1003	OK
36	INCOME_DOC	rule	INCOME_DOC	OK
37	TITLE_REPORT	rule	TITLE_REPORT	OK
38	URLA_1003	rule	URLA_1003	OK
39	CREDIT_REPORT	rule	CREDIT_REPORT	OK

package_01 문서 그룹핑 결과

총 39페이지 -〉 39개 그룹
(전부 1페이지짜리 그룹 - 위 '주요 발견' 참고)

package_02 페이지별 분류 결과 (정답 없음, 참고용)

Page	Category	Source
1	TITLE_REPORT	llm:groq
2	CREDIT_REPORT	llm:groq
3	TITLE_REPORT	rule
4	CREDIT_REPORT	rule
5	TITLE_REPORT	rule
6	CREDIT_REPORT	rule
7	TITLE_REPORT	rule
8	CREDIT_REPORT	rule
9	TITLE_REPORT	llm:groq
10	CREDIT_REPORT	rule
11	OTHER	llm:groq
12	INCOME_DOC	rule
13	URLA_1003	rule
14	CREDIT_REPORT	rule
15	TITLE_REPORT	rule
16	URLA_1003	rule
17	TITLE_REPORT	rule
18	URLA_1003	rule
19	CREDIT_REPORT	rule
20	URLA_1003	rule
21	CREDIT_REPORT	rule
22	TITLE_REPORT	rule
23	URLA_1003	rule
24	CREDIT_REPORT	rule
25	URLA_1003	rule
26	OTHER	llm:groq
27	INCOME_DOC	rule
28	CREDIT_REPORT	rule
29	URLA_1003	rule
30	TITLE_REPORT	llm:groq
31	INCOME_DOC	rule
32	CREDIT_REPORT	llm:groq
33	TITLE_REPORT	llm:groq
34	CREDIT_REPORT	rule
35	URLA_1003	rule
36	INCOME_DOC	rule
37	URLA_1003	rule
38	CREDIT_REPORT	rule
39	INCOME_DOC	llm:groq
40	OTHER	llm:groq
41	CREDIT_REPORT	rule
42	TITLE_REPORT	rule
43	URLA_1003	rule
44	CREDIT_REPORT	rule

package_02 문서 그룹핑 결과

총 44페이지 -〉 44개 그룹
(전부 1페이지짜리 그룹)

OTHER로 분류된 페이지 (원인 미확인, 후속 검토 필요)
- page 11
- page 26
- page 40